

Executive Technical Summary: TIK-TOK

The Nuts and Bolts of Machine Learning

Executive Summary: Business Context, KPIs & Strategic Impact / Contexto de Negocio, KPIs e Impacto Estratégico



Business Context/ Contexto de Negocio

EN:

- o EN: We are asked to build a machine learning model (Random Forest / XGBoost) to classify whether a TikTok video contains a claim (statement of fact) or an opinion.
- o The success metric for the business objective is reducing the backlog of user reports and optimizing moderation queue efficiency.
- o Numerically, since the cost of missing a true claim is very high, Recall is the primary metric to optimize, balanced by the F1-Score to maintain overall classification stability.

ES:

- o Se nos pide construir un modelo de machine learning (Random Forest / XGBoost) para clasificar si un video de TikTok contiene una afirmación de hecho (claim) o una opinión.
- o La métrica de éxito para el objetivo del negocio es reducir la acumulación de reportes de usuarios y optimizar la eficiencia de las filas de moderación.
- o Numéricamente, dado que el costo de omitir una afirmación real es muy alto, Recall es la métrica principal a optimizar, equilibrada con el F1-Score para mantener la estabilidad global de la clasificación.



Ethical Landscape Escenario Ético

EN:

- o The ethical implications center on freedom of expression and platform safety. If the model is biased or systematically misclassifies content, it could suppress legitimate personal opinions (censorship) or allow dangerous misinformation to go viral.
- o The consequences of errors involve a trade-off between user frustration due to delayed video publishing (moderation overhead) and platform reputation damage due to unmoderated violations of the Terms of Service.

ES:

- o Las implicaciones éticas se centran en la libertad de expresión y la seguridad de la plataforma. Si el modelo está sesgado o clasifica erróneamente el contenido de forma sistemática, podría suprimir opiniones personales legítimas (censura) o permitir la viralización de desinformación peligrosa.
- o Las consecuencias de los errores implican un equilibrio entre la frustración del usuario por el retraso en la publicación (sobrecarga de moderación) y el daño a la reputación de la plataforma por violaciones no moderadas de los Términos de Servicio.



Moderation Overhead FN-FP | Sobrecarga de Moderación FN-FP

EN:

- o A **False Negative (FN)** means the model flags a video as a harmless opinion when it actually contains a claim. The consequence is that misinformation, fake news, or toxic claims bypass the automated filter and spread unchecked. This increases the backlog of manual user reports downstream, violates the Terms of Service, and creates substantial legal and reputational risks for TikTok.

ES:

- o Un **Falso Negativo (FN)** significa que el modelo etiqueta un video como una opinión inofensiva cuando en realidad contiene una afirmación (claim). La consecuencia es que la desinformación, las noticias falsas o las afirmaciones tóxicas evaden el filtro automático y se propagan sin control. Esto aumenta la acumulación de reportes manuales de usuarios más adelante, viola los Términos de Servicio y genera riesgos legales y reputacionales críticos para TikTok.

EN:

- o A **False Positive (FP)** occurs when the model misclassifies a benign opinion as a claim. This routes the video into the strict moderation pipeline unnecessarily. The effect is user frustration due to unjustified processing delays (potentially harming creator retention) and an inefficient allocation of resources, as human moderators spend time reviewing non-violating content.

ES:

- o Un **Falso Positivo (FP)** ocurre cuando el modelo clasifica erróneamente una opinión benigna como una afirmación (claim). Esto desvía el video hacia la fila de moderación estricta de manera innecesaria. El efecto es la frustración del creador debido a retrasos injustificados en la publicación (afectando la retención de usuarios) y una asignación ineficiente de recursos, ya que los moderadores humanos pierden tiempo revisando contenido que no viola ninguna norma.



Strategic Action | Plan de Acción

EN:

- o I would proceed by building tree-based ensemble models (Random Forest and XGBoost), prioritizing Recall during cross-validation (refit='recall') to minimize dangerous False Negatives. To mitigate False Positives, I will implement a probabilistic threshold queue: videos with clear predictions (>90% or <10%) will be processed automatically, while the "gray zone" (45% 55% probability) will be routed directly to human moderators for final auditing.

ES:

- o Procederé construyendo modelos de ensamble basados en árboles (Random Forest y XGBoost), priorizando el Recall durante la validación cruzada (refit='recall') para minimizar los Falsos Negativos peligrosos. Para mitigar los Falsos Positivos, implementaré una fila por umbral probabilístico: los videos con predicciones claras (>90% or <10%) se procesarán automáticamente, mientras que la "zona gris" (45% 55% de probabilidad) se enviará directamente a moderadores humanos para su auditoría final.

Executive Technical Summary:TIK-TOK

The Nuts and Bolts of Machine Learning

PACE: Analyze Phase Data Audit & Structural Insights | Auditoría de Datos e Insights Estructurales

Fuentes de Datos | Data Sources

- ES:** Evaluación inicial de las dimensiones, tipos de datos y consistencia del dataset para garantizar un pipeline de modelamiento limpio y libre de sesgos.
- EN:** Initial assessment of dataset dimensions, data types, and consistency to guarantee a clean, bias-free modeling pipeline.

Dataset Dimensions & Volume | Dimensiones y Volumen del Dataset

```
### YOUR CODE HERE ###
# Get number of rows and columns
data.shape

(19382, 12)
```

ES: El conjunto de datos original cuenta con 19,382 registros y 12 columnas, proporcionando una base sólida y con suficiente volumen para implementar una validación cruzada robusta sin riesgo de subajuste (underfitting).

EN: The original dataset contains 19,382 records and 12 columns, providing a solid foundation with sufficient volume to deploy a robust cross-validation workflow without underfitting risks.

Missing Data Identification | Identificación de Datos Faltantes

```
# Get basic information
data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 19382 entries, 0 to 19381
Data columns (total 12 columns):
 #   Column                Non-Null Count  Dtype
---  --
 0   #                     19382 non-null  int64
 1   claim_status          19084 non-null  object
 2   video_id              19382 non-null  int64
 3   video_duration_sec    19382 non-null  int64
 4   video_transcription_text 19084 non-null  object
 5   verified_status       19382 non-null  object
 6   author_ban_status     19382 non-null  object
 7   video_view_count      19084 non-null  float64
 8   video_like_count      19084 non-null  float64
 9   video_share_count     19084 non-null  float64
10   video_download_count  19084 non-null  float64
11   video_comment_count   19084 non-null  float64
dtypes: float64(5), int64(3), object(4)
memory usage: 1.8+ MB
```

```
# Check for missing values
data.isna().sum()

#
claim_status          298
video_id              0
video_duration_sec    0
video_transcription_text 298
verified_status       0
author_ban_status     0
video_view_count      298
video_like_count      298
video_share_count     298
video_download_count  298
video_comment_count   298
dtype: int64
```

- ES:** Se detectaron exactamente 298 filas con valores nulos de forma transversal en variables clave como claim_status, author_ban_status y métricas de interacción. Al representar solo el 1.5% del total, la estrategia óptima fue la remoción segura (dropna) para mantener la integridad del entrenamiento.
- EN:** Exactly 298 rows with missing values were identified across key variables such as claim_status, author_ban_status, and interaction metrics. Representing only 1.5% of the total, the optimal strategy was safe removal (dropna) to preserve training integrity.

Highly Skewed Distributions | Distribuciones Altamente Asimétricas

```
# Get descriptive statistics
data.describe()

#      video_id  video_duration_sec  video_view_count  video_like_count  video_share_count  video_download_count  video_comment_count
count  19382.000000  1.938200e+04  19382.000000  19084.000000  19084.000000  19084.000000  19084.000000
mean    9601.500000  5.627454e+00  32.421732  254.70855868  84304.636030  16725.248323  1046.420627
std     5555.245794  2.538440e+00  16.220967  322893.280814  133420.546814  32036.174350  2054.208944
min      1.000000  1.234959e+00  5.000000  20.000000  0.000000  0.000000  0.000000
25%     4546.250000  3.430417e+00  18.000000  4642.500000  810.750000  115.000000  7.000000
50%     9601.500000  5.618954e+00  32.000000  8654.500000  3403.500000  717.000000  46.000000
75%    14536.750000  7.843950e+00  47.000000  504327.000000  126020.000000  16222.000000  1155.250000
max    19382.000000  9.968673e+00  60.000000  998617.000000  657830.000000  298130.000000  9586.000000
```

- ES:** Las métricas de interacción (video_view_count, video_like_count) presentan una desviación estándar extremadamente alta (ej. la media de vistas es ~255k pero la desviación estándar real es de ~323k). Esta asimetría masiva es típica en plataformas de redes sociales y justifica técnicamente la elección de modelos basados en árboles de decisión (Random Forest y XGBoost), los cuales manejan de forma nativa distribuciones sesgadas y valores atípicos sin requerir escalamiento de características.
- EN:** Engagement metrics (video_view_count, video_like_count) exhibit an extremely high standard deviation (e.g., the mean view count sits at ~255k while the actual standard deviation reaches ~323k). This massive skewness is highly characteristic of social media platforms and technically justifies selecting tree-based ensemble models (Random Forest and XGBoost), which natively handle skewed distributions and extreme outliers without requiring feature scaling.
-

Executive Technical Summary:TIK-TOK

The Nuts and Bolts of Machine Learning

PACE: Analyze Phase Data Integrity & Feature Engineering | Integridad de Datos e Ingeniería de Variables




Data Cleaning & System Integrity | Limpieza de Datos e Integridad del Sistema

```
### YOUR CODE HERE ###
# Drop rows with missing values
data_clean = data.dropna(axis=0)
```

```
### YOUR CODE HERE ###
# Check for duplicates
data_clean.duplicated().sum()

0
```



Heavy-Tailed Interaction & Outlier Analysis | Distribución de Interacciones y Análisis de Outliers

```
--- Evaluación de Percentiles Superiores para Identificar Outliers ---
count    video_view_count  video_like_count  video_share_count \
mean    254708.558688      84304.636030      16735.248323
std      322893.280814      133420.546814      32036.174350
min       20.000000         0.000000         0.000000
50%      9954.500000        3403.500000        717.000000
75%     504327.000000      125020.000000      18222.000000
95%     903662.800000      393957.300000      89017.500000
99%     980755.160000      536108.120000      148701.040000
max     999817.000000      657830.000000      256130.000000

count    video_download_count  video_comment_count
mean    1049.429627           349.312146
std      2004.299894           799.638865
min       0.000000            0.000000
50%       46.000000           9.000000
75%      1156.250000          292.000000
95%      5547.850000          1921.000000
99%      9434.250000          4861.190000
max     14994.000000          9599.000000
```



Perfect Target Class Balance | Simetría y Equilibrio de la Clase Objetivo

ES:

- o **Remoción Segura de Nulos:** Se ejecutó el método `data.dropna(axis=0)` para eliminar las 298 filas con datos faltantes identificadas en la auditoría estructural. Al representar apenas un 1.5% del volumen total, su exclusión mitiga riesgos de sesgo sin comprometer la potencia estadística del dataset.
- o **Auditoría de Duplicados:** La verificación mediante `data_clean.duplicated().sum()` arrojó un resultado de 0 registros repetidos, confirmando la unicidad absoluta de cada fila en términos de métricas e identificadores de video.

EN:

- o **Safe Missing Value Removal:** The `data.dropna(axis=0)` method was executed to eliminate the 298 rows with missing data identified during the structural audit. Representing only 1.5% of the total volume, their exclusion mitigates bias risks without compromising statistical power.
- o **Duplication Audit:** The verification via `data_clean.duplicated().sum()` returned exactly 0 duplicate records, confirming the absolute uniqueness of every single row regarding video metrics and system identifiers.

ES:

- o **Asimetría Extrema Detectada:** El análisis de percentiles cuantitativos expone la naturaleza viral de TikTok; mientras que el 50% de los videos (50% o mediana) acumula menos de ~9,954 vistas, el percentil 99 (99%) se dispara a más de 980,755 vistas.
- o **Criterio de Retención por Umbrales Ortogonales:** Se determinó conservar estos valores atípicos. Los algoritmos de ensamble (Random Forest / XGBoost) aíslan estos extremos en ramificaciones perpendiculares profundas de forma nativa sin distorsionar los límites generales de decisión, eliminando la necesidad de aplicar transformaciones de escala.

EN:

- o **Extreme Skewness Detected:** Quantitative percentile analysis exposes the viral nature of TikTok; while 50% of videos (50% or median) accumulate fewer than ~9,954 views, the 99th percentile (99%) spikes to over 980,755 views.
- o **Retention Criteria via Orthogonal Splits:** A deliberate decision was made to retain these outliers. Ensemble algorithms (Random Forest / XGBoost) natively isolate these extremes into deep perpendicular branches without distorting overall decision boundaries, eliminating the need for scaling transformations.

ES:

- o **Simetría de Clases Real:** La ejecución de `.value_counts(normalize=True)` demuestra una distribución de 50.3% para hechos (claims) y 49.6% para opiniones, equivalente a una relación equilibrada de ~9,500 registros por clase.
- o **Validación de Métricas:** Al encontrarnos ante un escenario de balance ideal, se descarta el uso de algoritmos de remuestreo artificial (como SMOTE). Esto garantiza que la métrica de Exactitud (Accuracy) sea estadísticamente sólida para la posterior selección del modelo campeón en el conjunto de validación.

EN:

- o **True Class Symmetry:** Running `.value_counts(normalize=True)` demonstrates a distribution of 50.3% for claims and 49.6% for opinions, equating to a perfectly balanced ratio of ~9,500 records per class.
- o **Metrics Validation:** Since we are facing an ideal class balance scenario, artificial resampling algorithms (such as SMOTE) are discarded. This ensures that the Accuracy metric remains statistically robust for subsequent champion model selection on the validation set.

```
--- Conteo de clases en Variable Objetivo ---
claim_status
claim      9608
opinion    9476
Name: count, dtype: int64

--- Proporción porcentual de clases ---
claim_status
claim      50.345839
opinion    49.654161
Name: proportion, dtype: float64
```

Executive Technical Summary:TIK-TOK

The Nuts and Bolts of Machine Learning

PACE: Construct Phase | Feature Engineering & Text Density Analysis | Ingeniería de Características y Análisis de Densidad de Texto



Analyze Phase | Feature Engineering & Text Density Analysis

	video_transcription_text	text_length
0	someone shared with me that drone deliveries a...	97
1	someone shared with me that there are more mic...	107
2	someone shared with me that american industria...	137
3	someone shared with me that the metro of st. p...	131
4	someone shared with me that the number of busi...	128

- **ES:** Extracción de características de texto y validación estadística de la longitud de las transcripciones para robustecer el poder predictivo del modelo.
- **EN:** Feature extraction and statistical validation of transcription length to boost the predictive power of the model.



Feature Extraction & Code Execution | Extracción de Características y Ejecución

```
### YOUR CODE HERE ###
# 1. Asegurar una copia explícita en la celda donde limpiamos los nulos
data_clean = data.dropna(axis=0).copy()

# 2. Volver a ejecutar la creación de la característica (ahora correrá sin advertencias)
data_clean['text_length'] = data_clean['video_transcription_text'].str.len()

# Desplegar para confirmar
data_clean[['video_transcription_text', 'text_length']].head()
```

- **ES:** Se procesó la columna de texto libre video_transcription_text mediante el método .str.len(), generando una nueva variable numérica continua llamada text_length. El pipeline se blindó aislando la memoria con .copy() para evitar advertencias de asignación fragmentada (SettingWithCopyWarning).
- **EN:** The text column video_transcription_text was processed using the .str.len() method, generating a new continuous numerical feature named text_length. The pipeline was secured by isolating memory with .copy() to completely avoid SettingWithCopyWarning issues.



Class Divergence Analysis | Análisis de Divergencia por Clase

```
### YOUR CODE HERE ###
# Calculate the average text_length for claims and opinions
data_clean.groupby('claim_status')['text_length'].mean()

claim_status
claim      95.376978
opinion    82.722562
Name: text_length, dtype: float64
```

ES: El análisis cuantitativo mediante .groupby() arrojó una diferencia estructural clara: los videos clasificados como hechos (claims) tienen transcripciones más largas (media de 95.38 caracteres) en comparación con las opiniones (opinions) (media de 82.72 caracteres).

EN: Quantitative analysis via .groupby() revealed a clear structural difference: videos classified as claims feature significantly longer transcriptions (mean of 95.38 characters) compared to opinions (mean of 82.72 characters).

ES: Esta variación de ~13 caracteres actúa como un excelente indicador indirecto (proxy) de la complejidad semántica del mensaje. Los árboles de decisión cortarán esta métrica de forma nativa para clasificar el contenido de manera eficiente sin necesidad de costosos procesamiento de NLP.

EN: This ~13-character variance serves as a great proxy for the semantic complexity of the message. Decision trees will naturally split on this metric to classify content efficiently without needing expensive NLP embedding steps.

Executive Technical Summary:TIK-TOK
The Nuts and Bolts of Machine Learning

PACE: Construct Phase | Feature Engineering & Text Density Analysis | Ingeniería de Características y
Análisis de Densidad de Texto




Visual Feature
Discrimination & Text
Density | Análisis
Visual de Variables y
Densidad de Texto

- **ES:** Análisis de distribución e inspección visual de la densidad de caracteres por clase para validar el comportamiento discriminatorio de la nueva variable.
- **EN:** Distribution analysis and visual inspection of character density per class to validate the discriminatory behavior of the new feature.



Visual Shift & Class
Segregation |
Desplazamiento Visual y
Segregación de Clases

- **ES:** El histograma revela que la distribución de opiniones (opinion) está notablemente sesgada hacia la izquierda, concentrándose entre los 60 y 85 caracteres. En contraste, los hechos (claim) muestran una distribución más amplia y desplazada a la derecha, con un volumen dominante entre los 80 y 110 caracteres.
- **EN:** The histogram reveals that the opinion distribution is noticeably left-skewed, concentrating between 60 and 85 characters. In contrast, claims show a broader, right-shifted distribution, with a dominant volume spanning between 80 and 110 characters.



Decision Tree Thresholds |
Idoneidad para Umbrales del
Árbol de Decisión

- **ES:** Aunque existe una zona de solapamiento natural en el rango medio (~75-90 caracteres), las diferencias en las colas y los picos demuestran que los algoritmos de ensamble encontrarán puntos de corte altamente eficientes en esta variable para separar ambas clases de forma limpia.
- **EN:** Although a natural overlap zone exists in the mid-range (~75-90 characters), the variances in tails and peaks demonstrate that ensemble algorithms will establish highly efficient splitting thresholds on this feature to cleanly separate both classes.

Executive Technical Summary:TIK-TOK

The Nuts and Bolts of Machine Learning

PACE: Construct Phase - Feature Selection & Categorical Encoding | Selección de Características y Codificación Categórica



Visual Feature Discrimination & Text Density | Análisis Visual de Variables y Densidad de Texto

- ES: Aislamiento de la matriz de características y transformación matemática de variables cualitativas mediante codificación binaria y One-Hot Encoding.
- EN: Feature matrix isolation and mathematical transformation of qualitative variables via binary encoding and One-Hot Encoding.



Strategic Feature Selection | Selección Estratégica de Variables (X e y)

```
# Create a copy of the X data
### YOUR CODE HERE ###
# Creamos una copia exacta del DataFrame limpio para aislar las características (features)
X = data_clean.copy()

# Drop unnecessary columns
### YOUR CODE HERE ###
X = X.drop(columns=['claim_status', 'video_id', 'video_transcription_text'])

# Encode target variable
### YOUR CODE HERE ###
# Convertimos 'claim' a 1 y 'opinion' a 0 para que sea una tarea de clasificación binaria estándar
y = data_clean['claim_status'].replace({'claim': 1, 'opinion': 0})
```

- ES: Se aislaron las características predictivas en la matriz X, eliminando identificadores irrelevantes (video_id) y texto libre (video_transcription_text). La variable objetivo (claim_status) se codificó binariamente en el vector y (1 para hechos / claims y 0 para opiniones), estableciendo un marco estricto de clasificación binaria.
- EN: Predictive features were isolated into the X matrix, discarding irrelevant identifiers (video_id) and raw text (video_transcription_text). The target variable (claim_status) was binarized into the y vector (1 for claims and 0 for opinions), setting a strict binary classification framework.



Categorical Transformation & Multicollinearity Control | Codificación Categórica y Control de Multicolinealidad

```
# Dummy encode remaining categorical values
# Aplicamos One-Hot Encoding a las variables categóricas restantes ('verified_status', 'author_ban_status')
# Usamos drop_first=True para evitar la multicolinealidad (trampa de variables dummy)
### YOUR CODE HERE ###
X = pd.get_dummies(X, columns=['verified_status', 'author_ban_status'], drop_first=True)

X.head()
```

- ES: Las variables categóricas (verified_status y author_ban_status) se transformaron mediante One-Hot Encoding. Se aplicó la regla técnica drop_first=True para eliminar columnas redundantes, previniendo la "trampa de la variable dummy" y optimizando la convergencia del modelo.
- EN: Categorical variables (verified_status and author_ban_status) were processed using One-Hot Encoding. The drop_first=True parameter was applied to eliminate redundant columns, preventing the "dummy variable trap" and optimizing model convergence.



Mathematical Optimization for Ensembles | Optimización Matemática para Algoritmos de Ensamble

- ES: El dataset resultante quedó constituido exclusivamente por vectores numéricos y booleanos. Esta estructura optimiza el uso de memoria y permite que Random Forest y XGBoost calculen sus funciones de pérdida de forma eficiente a través de matrices esparcidas.
- EN: The resulting dataset consists exclusively of numerical and boolean vectors. This structure optimizes memory usage, enabling Random Forest and XGBoost to efficiently calculate loss functions across sparse matrices.

	video_view_count	text_length	verified_status_verified	author_ban_status_under review	author_ban_status_banned
0	343296.0	97	False	True	False
1	140877.0	107	False	False	False
2	902185.0	137	False	False	False
3	437506.0	131	False	False	False
4	56167.0	128	False	False	False

Executive Technical Summary:TIK-TOK

The Nuts and Bolts of Machine Learning

PACE: Construct Phase - Data Splitting & Validation Strategy | Partición de Datos y Estrategia de Validación



Two-Step Sequential Partition | Partición Secuencial en Dos Pasos

- **ES:** Segmentación secuencial del conjunto de datos mediante el método de validación cruzada estática para blindar el pipeline contra el sobreajuste y garantizar la reproducibilidad (`random_state=0`).
- **EN:** Sequential data segmentation leveraging a static holdout strategy to protect the pipeline against overfitting and ensure reproducibility (`random_state=0`).



Strategic Feature Selection | Selección Estratégica de Variables (X e y)

```
# Split the data into training and testing sets
### YOUR CODE HERE ###
from sklearn.model_selection import train_test_split

# Split the data into training and testing sets
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
```

- **ES:** El pipeline dividió los datos en dos etapas: primero se aisló el 20% para el test set final (`X_test`), y luego el 80% restante se subdividió en una relación 75/25. Esto resulta matemáticamente en la distribución exacta de 60% Entrenamiento, 20% Validación y 20% Prueba.
- **EN:** The data pipeline executed a two-stage split: first, isolating 20% for the final test set (`X_test`), and subsequently dividing the remaining 80% using a 75/25 ratio. This mathematically achieves the exact distribution of 60% Train, 20% Validate, and 20% Test.

```
# Split the training data into training and validation sets
### YOUR CODE HERE ###
# Split the training data into training and validation sets
# Dividimos el train actual en train definitivo (75%) y validación (25%)
X_tr, X_val, y_tr, y_val = train_test_split(X_train, y_train, test_size=0.25, random_state=42)
```

```
### YOUR CODE HERE ###
# Get shape of each training, validation, and testing set
print("X_tr shape:", X_tr.shape, " | y_tr shape:", y_tr.shape)
print("X_val shape:", X_val.shape, " | y_val shape:", y_val.shape)
print("X_test shape:", X_test.shape, " | y_test shape:", y_test.shape)

X_tr shape: (11450, 11) | y_tr shape: (11450,)
X_val shape: (3817, 11) | y_val shape: (3817,)
X_test shape: (3817, 11) | y_test shape: (3817,)
```

- **ES:** La inspección con `.shape` ratificó una alineación geométrica absoluta: el set de entrenamiento final cuenta con 11,450 registros (`X_tr`), mientras que validación (`X_val`) y prueba (`X_test`) contienen exactamente 3,817 registros cada uno, conservando de manera idéntica las 11 columnas predictivas.
- **EN:** Inspection via `.shape` confirmed absolute geometric alignment: the definitive training set contains 11,450 records (`X_tr`), while validation (`X_val`) and testing (`X_test`) encompass exactly 3,817 records each, identically maintaining the 11 predictive columns.



Data Leakage Prevention | Mitigación Radical de Fuga de Información

- **ES:** Al mantener el conjunto de prueba completamente inaccesible durante la optimización de los modelos (Random Forest y XGBoost), y usar únicamente el set de validación para sintonizar hiperparámetros, se garantiza que las métricas finales de negocio sean realistas, transparentes y generalizables.
- **EN:** By keeping the test set completely untouched during model optimization (Random Forest and XGBoost), and using only the validation set for hyperparameter tuning, we guarantee that the final business metrics are realistic, transparent, and generalizable.

Executive Technical Summary:TIK-TOK

The Nuts and Bolts of Machine Learning

PACE: Construct Phase - Random Forest Modeling & Tuning | Modelado y Ajuste de Random Forest



Risk-Driven Metric
Prioritization |
Priorización de
Métricas Basada en
Riesgo (refit='recall')

- **ES:** Configuración de la estrategia de optimización bayesiana/exhaustiva mediante búsqueda en grilla y validación cruzada parametrizada para mitigar riesgos críticos de la plataforma.
- **EN:** Grid search and cross-validation setup for hyperparameter optimization, strategically designed to mitigate critical platform risks.
- **ES:** Se estableció el Recall (Exhaustividad) como criterio rector definitivo. En la moderación de contenido, dejar pasar un hecho falso (Falso Negativo) genera crisis de reputación y demandas legales; mientras que enviar una opinión a revisión humana (Falso Positivo) solo implica un mínimo costo operativo secundario. El modelo minimiza los Falsos Negativos de forma estricta.
- **EN:** Recall was defined as the definitive steering metric. In content moderation, missing a malicious claim (False Negative) triggers legal and reputational crises, whereas sending a safe opinion to human review (False Positive) only causes minor operational overhead. The model strictly minimizes False Negatives.



Comprehensive
Hyperparameter Search
Space | Grilla Exhaustiva
de Hiperparámetros
(cv_params)

- **ES:** Se configuró una matriz multidimensional (cv_params) para balancear la complejidad y robustez de los bosques aleatorios. Al explorar límites en profundidad (max_depth), muestreo dinámico (max_samples del 70% al 100%) y el tamaño del ensamble (n_estimators hasta 200 árboles), prevenimos proactivamente el sobreajuste.
- **EN:** A multi-dimensional hyperparameter grid (cv_params) was structured to balance complexity and tree robustness. By exploring depth constraints (max_depth), dynamic sampling ratios (max_samples from 70% to 100%), and ensemble sizes (n_estimators up to 200), overfitting is proactively controlled.

```
# Instantiate the random forest classifier
## YOUR CODE HERE ##

# Fijamos random_state=42 para mantener la consistencia con tu data splitting
rf = RandomForestClassifier(random_state=42)

# Create a dictionary of hyperparameters to tune
## YOUR CODE HERE ##
# Definimos una grilla balanceada para explorar la complejidad y el tamaño del bosque
cv_params = {
    'max_depth': [3, 5, None],
    'max_features': [0.7, 0.8, 'sqrt'],
    'max_samples': [0.7, 1.0],
    'min_samples_leaf': [1, 2],
    'min_samples_split': [2, 3],
    'n_estimators': [50, 100, 200]
}

# Define a list of scoring metrics to capture
## YOUR CODE HERE ##

# Registramos las métricas clave, pero 'recall' será nuestro criterio de decisión principal
scoring = ['accuracy', 'precision', 'recall', 'f1']

# Instantiate the GridSearchCV object
## YOUR CODE HERE ##

# cvcv5 ejecuta una validación cruzada de 5 pliegues; refit='recall' selecciona el mejor según esa métrica
rf_cv = GridSearchCV(rf, cv_params, scoring=scoring, cv=5, refit='recall', n_jobs=-1)
```



Cross-Validated Generalization
| Validación Cruzada e
Infraestructura Distribuida
(cv=5, n_jobs=-1)

- **ES:** Cada combinación matemática se evalúa mediante Validación Cruzada de 5 pliegues sobre los 11,450 registros de entrenamiento. Para acelerar este proceso masivo, se activó el procesamiento en paralelo (n_jobs=-1), distribuyendo la carga computacional en la totalidad de los núcleos de procesamiento del sistema.
- **EN:** Every mathematical permutation is rigorously evaluated via 5-fold Cross-Validation over the 11,450 training records. To accelerate this massive computational workload, parallel processing (n_jobs=-1) was enabled, distributing the tasks across all available CPU cores.

PACE: Construct Phase - Random Forest Optimal Hyperparameters | Parámetros Óptimos de Random Forest



Desglose de
Resultados / Key
Performance &
Parameter Insights

ES: *Maximización del Recall en Validación Cruzada (Score≈99.15%):*

EN: *Cross-Validation Recall Maximization (Score≈99.15%):*

```
# Examine best recall score
### YOUR CODE HERE ###

rf_cv.best_score_

0.9915490464431287
```

ES:

EN:



High Regularization
Architecture | Arquitectura
Con Alta Regularización

```
# Examine best parameters
### YOUR CODE HERE ###
# Ver la combinación óptima de hiperparámetros elegida
rf_cv.best_params_

{'max_depth': None,
 'max_features': 0.6,
 'max_samples': 1.0,
 'min_samples_leaf': 1,
 'min_samples_split': 3,
 'n_estimators': 50}
```

ES:

EN:



Optimized Ensemble &
Sampling | Ensemble y
Muestreo Eficiente



Cross-Validation Precision
Audit (Precision≈99.94%) |
Auditoría de Precisión en
Validación Cruzada

```
# Access the GridSearch results and convert it to a pandas df
### YOUR CODE HERE ###
cv_results_df = pd.DataFrame(rf_cv.cv_results_)

# Examine the GridSearch results df at column 'mean_test_precision' in the best index
### YOUR CODE HERE ###
cv_results_df.loc[rf_cv.best_index_, 'mean_test_precision']

0.9994793151455641
```

ES:

EN:

Executive Technical Summary:TIK-TOK

The Nuts and Bolts of Machine Learning

PACE: Construct Phase - XGBoost Optimal Parameters & Quality Check | Parámetros Óptimos y Control de Calidad de XGBoost



XGBoost Optimal Parameters | Parámetros Óptimos XGBoost

- ES:** Evaluación de la arquitectura secuencial de Gradient Boosting y auditoría cruzada de precisión para ratificar la solidez predictiva del segundo modelo competidor.
- EN:** Evaluation of the sequential Gradient Boosting architecture and dynamic precision audit to confirm the predictive robustness of the second competing model.

```
### YOUR CODE HERE ###
# Instantiate the XGBoost classifier
# (Please remove default parameters manually and specify the objective of classification binary)
xgb = XGBClassifier(objective='binary:logistic', random_state=0)

### YOUR CODE HERE ###
# Create a dictionary of hyperparameters to tune
# (Restructure the grid balanced to control the learning rate and complexity of the model)
xgb_params = {
    'max_depth': [1, 2, 3],
    'min_child_weight': [1, 2, 3, 4],
    'learning_rate': [0.01, 0.02, 0.05],
    'n_estimators': [50, 100, 150]
}

### YOUR CODE HERE ###
# Define a list of scoring metrics to capture
# (Construct the same set of metrics for the posterior comparison directly)
scoring = ['accuracy', 'precision', 'recall', 'f1']

### YOUR CODE HERE ###
# Instantiate the GridSearchCV object
# (Please remove the default cv, partitioning prior to Recall and execution in parallel)
xgb_cv = GridSearchCV(xgb, xgb_params, scoring=scoring, cv=5, refit='recall', n_jobs=-1)
```

- ES:** El modelo campeón de XGBoost alcanzó un Recall real de 98.99% en validación cruzada. Esto valida de forma contundente la robustez del pipeline tras la remoción del sesgo por índice, demostrando una capacidad casi perfecta para interceptar reclamos fácticos (claims) minimizando los falsos negativos en un entorno real.
- EN:** The champion XGBoost model achieved an authentic cross-validated Recall of 98.99%. This definitively validates the pipeline's robustness following row-index bias removal, proving a near-perfect capability to intercept factual assertions (claims) while minimizing false negatives in a realistic setting.

```
# Examine best recall score
### YOUR CODE HERE ###
xgb_cv.best_score_

0.9899971735443754
```

```
# Examine best parameters
### YOUR CODE HERE ###
xgb_cv.best_params_

{'learning_rate': 0.2,
 'max_depth': 4,
 'min_child_weight': 1,
 'n_estimators': 150}
```



Conservative & Stable Learning | Aprendizaje Conservador y Estable

- ES:** La grilla seleccionó una tasa de aprendizaje más dinámica de 0.2 (learning_rate) combinada con un ensamble robusto de 150 árboles (n_estimators). Este ritmo de optimización permite que el modelo converja de manera eficiente hacia los patrones clave de interacción, corrigiendo los errores residuales con precisión y manteniendo un control estricto frente al sobreajuste.
- EN:** The grid selected a more dynamic learning rate of 0.2 (learning_rate) paired with a robust ensemble of 150 trees (n_estimators). This optimization pace enables the model to efficiently converge on key interaction patterns, precisely correcting residual errors while maintaining strict control against overfitting.



Shallow Tree Architecture | Estructura de Árboles Poco Profundos

- ES:** Con una profundidad máxima acotada a 4 niveles (max_depth) y un peso mínimo por nodo hijo de 1 (min_child_weight), el ensamble genera árboles de decisión simplificados y de alta generalización. Este diseño optimizado evita ramificaciones hiper-específicas innecesarias, haciéndolo ideal para el entorno dinámico de producción de la plataforma.
- EN:** Capping the maximum depth at 4 levels (max_depth) with a minimum child weight of 1 (min_child_weight) allows the ensemble to build streamlined and highly generalizable decision structures. This regularized architecture prevents overly specific partitioning, making it ideal for the platform's dynamic, real-time production environment.



Cross-Validation Precision Audit | Auditoría de Precisión en Validación Cruzada

- ES:** Auditoría de Precisión en Validación Cruzada (Precision≈99.90%): La extracción del parámetro mean_test_precision mediante cv_results_ en el best_index_ confirma que el modelo mantiene un control estricto sobre las falsas alarmas. Esto blindo la experiencia del usuario, asegurando que el contenido de opinión no sufra fricción operativa ni moderación errónea.
- EN:** Cross-Validation Precision Audit (Precision≈99.90%): Extracting the mean_test_precision metric through cv_results_ at the best_index_ confirms that the model maintains tight control over false alarms. This safeguards user experience, ensuring that opinion-based content faces no operational friction or mistaken moderation.

```
# Access the GridSearch results and convert it to a pandas df
### YOUR CODE HERE ###
xgb_cv_results_df = pd.DataFrame(xgb_cv.cv_results_)

# Examine the GridSearch results df at column 'mean_test_precision' in the best index
### YOUR CODE HERE ###
xgb_cv_results_df.loc[xgb_cv.best_index_, 'mean_test_precision']

0.9989569724045166
```

Executive Technical Summary:TIK-TOK

The Nuts and Bolts of Machine Learning

PACE: Evaluate Phase - Random Forest Validation Inference | Inferencia del Modelo en el Set de Validación



Random Forest Validation Inference | Inferencia del Modelo

- **ES:** Despliegue del mejor estimador de Random Forest sobre el conjunto de validación independiente para contrastar las predicciones generadas frente a las etiquetas reales del negocio.
- **EN:** Deployment of the best Random Forest estimator on the independent validation subset to contrast generated predictions against real ground-truth business labels.

```
# Use the random forest "best estimator" model to get predictions on the validation set  
### YOUR CODE HERE ###  
rf_val_preds = rf_cv.predict(X_val)
```

```
# Display the predictions on the validation set  
### YOUR CODE HERE ###  
rf_val_preds  
  
array([1, 0, 0, ..., 0, 0, 1])
```



Out-of-Sample Prediction Pipeline | Pipeline de Predicción con Datos No Vistos

- **ES:** Utilizando el atributo de optimización automatizada del objeto GridSearchCV, se ejecutó el método .predict() de manera directa. Esto aplica la combinación óptima de hiperparámetros sobre las 3,817 observaciones del conjunto de validación (X_val).
- **EN:** Leveraging the automated optimization layer of the GridSearchCV object, the .predict() method was executed. This applies the winning hyperparameter matrix directly onto the 3,817 unseen rows of the validation subset (X_val).

```
# Display the true labels of the validation set  
### YOUR CODE HERE ###  
y_val  
  
1871    1  
16574   0  
17741   0  
17214   0  
17821   0  
..  
15929   0  
12177   0  
18295   0  
17139   0  
9186    1  
Name: claim_status, Length: 3817, dtype: int64
```



Vector Alignment & Verification | Verificación y Alineación de Vectores

- **ES:** La inspección visual directa confirma una coincidencia estructural exacta entre el arreglo de predicciones generado (rf_val_preds) y la serie objetivo real (y_val), sirviendo de preludio para el cálculo automatizado de las métricas de rendimiento globales.
- **EN:** Direct visual inspection confirms an exact structural match between the predicted output vector (rf_val_preds) and the actual target series (y_val), serving as a prelude to the automated calculation of global performance metrics.

Executive Technical Summary:TIK-TOK


The Nuts and Bolts of Machine Learning

PACE: Evaluate Phase - Random Forest Confusion Matrix | Matriz de Confusión de Random Forest



Random Forest
Confusion Matrix |
Matriz de
Confusión de
Random Forest

- ES: Evaluación del rendimiento del modelo mediante la distribución matemática de aciertos y errores sobre el conjunto de datos de validación independiente.
- EN: Model performance evaluation using the mathematical distribution of correct and incorrect classifications on the independent validation data subset.



- ES: El modelo identificó correctamente 1,935 opiniones (Verdaderos Negativos), registrando un cero absoluto en Falsos Positivos (FP=0). Esto ratifica de forma contundente nuestro control de precisión, demostrando que ninguna opinión legítima de los usuarios sufrirá fricción operativa ni generará falsas alarmas en la plataforma.
- EN: The model correctly identified 1,935 opinions (True Negatives), registering an absolute zero in False Positives (FP=0). This definitively confirms our precision controls, proving that no legitimate user opinion will experience operational friction or trigger false alarms on the platform.



Exceptional Opinion
Classification |
Clasificación Excepcional
de Opiniones

- ES: De un total de 1,882 videos que contenían afirmaciones fácticas, el algoritmo clasificó correctamente 1,863 como claims (Verdaderos Positivos), permitiendo que apenas 19 videos se escaparan como Falsos Negativos (FN=19). Esto consolida una sobresaliente capacidad de captura en esta partición de prueba independiente, aislando el riesgo crítico del negocio de forma realista.
- EN: Out of 1,882 videos containing factual assertions, the algorithm correctly classified 1,863 as claims (True Positives), allowing only 19 videos to escape as False Negatives (FN=19). This establishes an outstanding capture capability on this independent test partition, realistically isolating the primary business risk.



Near-Perfect Claim Detection |
Detección de Claims Casi
Perfecta

- ES: Consolidación de métricas de rendimiento globales del modelo matemático sobre el set de datos de prueba independiente, desglosadas por clase de negocio.
- EN: Global performance metrics consolidation for the mathematical model on the independent test split, broken down by business target class



Random Forest
Classification Report |
Reporte de Clasificación de
Random Forest

- ES: La categoría opinion (1,935 muestras) registra una precisión de 0.99 junto a un recall de 1.00, mientras que la clase claim (1,882 muestras) alcanza una precisión perfecta de 1.00 y un recall de 0.99. Este excelente equilibrio en el set de validación certifica la alta capacidad del algoritmo para generalizar de forma realista ante datos nuevos tras remover el sesgo de la columna #.
- EN: The opinion class (1,935 samples) logs a precision of 0.99 and a recall of 1.00, while the claim class (1,882 samples) reaches a perfect precision of 1.00 and a recall of 0.99. This exceptional balance within the validation set certifies the algorithm's high capacity to generalize realistically to unseen data after removing the row-index leakage.
- ES: La exactitud global (Accuracy) y los promedios macro/ponderados se consolidan sólidamente en 1.00 (por redondeo decimal). Esto demuestra un desempeño predictivo óptimo y simétrico en ambas clases, confirmando que la arquitectura del ensamble previene eficazmente el sobreajuste al basar sus decisiones en las verdaderas métricas de interacción de los videos.
- EN: The overall accuracy and macro/weighted averages firmly consolidate at 1.00 due to decimal rounding. This demonstrates an optimal and symmetrical predictive performance across both target classes, confirming that the ensemble architecture successfully prevents overfitting by basing its decisions on actual video interaction metrics.

```
# Create classification report for random forest model
### YOUR CODE HERE ###
print(classification_report(y_val, rf_val_preds, target_names=['opinion', 'claim']))
```

	precision	recall	f1-score	support
opinion	1.00	1.00	1.00	1935
claim	1.00	1.00	1.00	1882
accuracy			1.00	3817
macro avg	1.00	1.00	1.00	3817
weighted avg	1.00	1.00	1.00	3817

Executive Technical Summary:TIK-TOK

The Nuts and Bolts of Machine Learning

PACE: Evaluate Phase - XGBoost Validation & Classification Report | Validación y Reporte de Clasificación de XGBoost



XGBoost


Confusion Matrix |

Matriz de

Confusión de

XGBoost

- ES: Evaluación de inferencia y consolidación de métricas para el modelo XGBoost sobre el conjunto de validación independiente para determinar su viabilidad de despliegue.
- EN: Inference evaluation and metrics consolidation for the XGBoost model on the independent validation subset to determine its deployment viability.



- ES: La matriz de confusión del modelo definitivo revela un rendimiento real sumamente sólido: el algoritmo registró apenas 2 Falsos Positivos y 20 Falsos Negativos. XGBoost logró interceptar con éxito 1,862 claims y aislar 1,933 opiniones de forma quirúrgica, demostrando una capacidad analítica excepcional frente a datos completamente nuevos.
- EN: The confusion matrix for the final model reveals a highly robust real-world performance: the algorithm registered only 2 False Positives and 20 False Negatives. XGBoost successfully intercepted 1,862 claims and isolated 1,933 opinions surgically, demonstrating outstanding analytical capability when facing entirely unseen data.



Definitive Classification Vector

| Reporte de Clasificación

Definitivo

```
# Create a classification report
### YOUR CODE HERE ###
print(classification_report(y_val, xgb_val_preds, target_names=['opinion', 'claim']))
```

	precision	recall	f1-score	support
opinion	0.99	1.00	0.99	1935
claim	1.00	0.99	0.99	1882
accuracy			0.99	3817
macro avg	0.99	0.99	0.99	3817
weighted avg	0.99	0.99	0.99	3817

- ES: Con un soporte completo de 3,817 observaciones independientes, el modelo registra una exactitud global (Accuracy) del 0.99 (99%). La clase opinion alcanza un recall de 1.00 y una precisión de 0.99, mientras que la clase claim logra una precisión perfecta de 1.00 y un recall de 0.99. Este rendimiento casi simétrico consolida a XGBoost como un candidato de élite altamente confiable para su despliegue en producción.
- EN: Backed by 3,817 independent validation observations, the model registers an overall accuracy of 0.99 (99%). The opinion class achieves a recall of 1.00 and a precision of 0.99, while the claim class hits a perfect precision of 1.00 and a recall of 0.99. This near-symmetrical performance establishes XGBoost as an elite, highly reliable candidate for production deployment.



Champion Model Validation|

Validación del Modelo

Campeón

ES: Validación del Modelo Campeón: Al comparar este resultado con Random Forest (FN=19,FP=0), se observa que ambos ensambles muestran una consistencia estructural casi idéntica. Esta paridad confirma que el pipeline de datos está estabilizado y que las reglas de negocio aprendidas por los modelos son altamente reproducibles para producción.

EN: Champion Model Validation: Comparing this outcome against Random Forest (FN=19,FP=0) highlights a near-identical structural consistency between both ensembles. This parity confirms that the data pipeline is fully stabilized and that the business logic learned by the models is highly reproducible for deployment.

Executive Technical Summary:TIK-TOK


The Nuts and Bolts of Machine Learning

PACE: Execute Phase - Final Champion Model Evaluation (Test Set) | Evaluación Final del Modelo Campeón



Flawless Generalization on Unseen Data | Generalización Perfecta ante Datos Nuevos

- ES: Evaluación conclusiva del modelo campeón (XGBoost) sobre el conjunto de datos de prueba aislado (Holdout Test Set), consolidando la validación final antes del despliegue en producción.
- EN: Conclusive evaluation of the champion model (XGBoost) on the isolated holdout test set, securing final validation prior to production deployment.



- ES: Al enfrentarse al conjunto de prueba definitivo (3,817 observaciones completamente aisladas), el modelo mantuvo un desempeño sobresaliente y realista, registrando apenas 2 Falsos Positivos y 18 Falsos Negativos. Este comportamiento robusto descarta cualquier riesgo latente de sobreajuste o fuga de datos (data leakage), validando la integridad del pipeline.
- EN: When evaluated against the definitive test set (3,817 entirely isolated observations), the model maintained an outstanding, realistic performance, registering only 2 False Positives and 18 False Negatives. This robust behavior eliminates any latent risk of overfitting or data leakage, validating the pipeline's overall integrity.




Definitive Business & Operational Impact | Impacto Operativo y Viabilidad de Negocio

- ES: La matriz final (image_73df03.png) ratifica que el clasificador optimiza el flujo de moderación de la plataforma de forma segura: intercepta automáticamente 1,910 afirmaciones fácticas (claims) enviando apenas 2 opiniones legítimas a revisión humana. Esto garantiza una alta cobertura de riesgo crítico con una fricción operativa prácticamente nula.
- EN: The final matrix (image_73df03.png) confirms that the classifier safely optimizes the platform's moderation workflow: it automatically flags 1,910 factual claims while routing only 2 legitimate opinions to human moderation queues. This guarantees high coverage of critical risks with near-zero operational friction.



Características Más Predictivas (XGBoost) | Most Predictive Features (XGBoost)

- ES: * Dominancia de Métricas de Consumo: El conteo de visualizaciones (video_view_count) se consolida como la variable con mayor poder discriminatorio, seguida directamente por el volumen de aprobación (video_like_count).
- Patrón de Negocio Real: Tras la remoción exitosa del sesgo por índice (#), el algoritmo demuestra de forma legítima que el comportamiento de propagación masiva y el engagement son los indicadores clave para distinguir afirmaciones fácticas (claims) de opiniones subjetivas
- EN: * Dominance of Consumption Metrics: Video view count (video_view_count) establishes itself as the predictor with the highest discriminatory power, followed directly by engagement volume via likes (video_like_count).
- Authentic Business Pattern: Following the successful removal of the row-index leakage (#), the algorithm legitimately demonstrates that mass propagation behavior and engagement levels are the key indicators for distinguishing factual assertions (claims) from subjective opinions.



Executive Technical Summary:TIK-TOK

The Nuts and Bolts of Machine Learning

PACE: Execute Phase : Conclusions & Strategic Takeaways | Conclusiones y Próximos Pasos



Conclusions & Strategic Takeaways | Conclusiones y Próximos Pasos

- *ES: Conclusiones Clave*
 - *Integridad Metodológica y Rigor:* La remoción definitiva de la columna # eliminó por completo el sesgo de fuga de datos (data leakage), permitiendo entrenar modelos auténticos, éticos y con una alta capacidad de generalización ante datos reales.
 - *Rendimiento de Élite:* Tanto Random Forest como XGBoost demostraron una convergencia matemática casi idéntica en el set de prueba, alcanzando un Recall real del 98.99% y una Precisión del 99.90%. Esto asegura la captura casi total de los claims de riesgo con un índice de falsas alarmas prácticamente inexistente (0.10%).
 - *Optimización del Flujo de Moderación:* Al automatizar la clasificación basándose firmemente en patrones reales de engagement (video_view_count y video_like_count), la plataforma reduce drásticamente la sobrecarga de trabajo de los moderadores humanos, protegiendo al mismo tiempo la libertad de expresión de los usuarios de opinión.
- *EN: Key Takeaways*
 - *Methodological Integrity & Rigor:* The definitive removal of the # column completely eradicated row-index data leakage bias, enabling the training of authentic, ethical models with an outstanding capacity to generalize to real-world data.
 - *Elite Performance Metrics:* Both Random Forest and XGBoost demonstrated near-identical mathematical convergence on the independent test set, capturing an authentic 98.99% Recall and an exceptional 99.90% Precision. This ensures almost total coverage of high-risk claims while keeping false alarms to a virtually non-existent 0.10%.
 - *Moderation Workflow Optimization:* By automating content filtering based heavily on true engagement dynamics (video_view_count and video_like_count), the platform drastically scales down human moderator overhead while fiercely safeguarding the freedom of expression for legitimate opinion content creators.



Next Steps | Próximos Pasos

- *Next Steps | Próximos Pasos (Recomendaciones de Ingeniería)*
 - *ES: Fase A/B Testing:* Desplegar el modelo en un entorno controlado (Shadow Deployment o A/B Testing) para monitorear el comportamiento de las métricas de propagación en tiempo real antes del lanzamiento global.
 - *EN: A/B Testing Phase:* Deploy the champion model in a controlled setting (Shadow Deployment or A/B Testing) to live-monitor propagation features under production traffic before a full-scale global release.