Executive Report: TikTok Claims Classification (EDA Phase)

Project: TikTok Content Moderation | Client: TikTok Data Strategy Team PACE Phase: Analyze (Exploratory Data Analysis & Visualization)

Business Context/ Contexto de Negocio

- EN: TikTok's mission is to inspire creativity and bring joy. With millions of daily reports, the challenge is to prioritize user claims over opinions to optimize the moderation workflow and ensure platform safety.
- ES: La misión de TikTok es inspirar la creatividad y traer alegría. Con millones de informes diarios, el desafío es priorizar las reclamaciones de los usuarios sobre las opiniones para optimizar el flujo de trabajo de moderación y garantizar la seguridad de la plataforma.

Project Overview / Visión General del Proyecto

- EN: Goal: Develop a predictive model to distinguish between claims and opinions. Current EDA focuses on identifying data patterns, handling outliers in engagement metrics, and preparing the dataset for model training.
- ES: Objetivo: Desarrollar un modelo predictivo para distinguir entre reclamaciones y opiniones. El EDA actual se centra en identificar patrones de datos, gestionar valores atípicos en métricas de interacción y preparar el conjunto de datos para el entrenamiento del modelo.

Business Questions/ Preguntas de Negocio

- What is the relative volume of claims versus opinions within the current user reports?
- Are there significant differences in engagement metrics (views, likes, shares) between both content types?
- How does verification status impact content reach?

- ¿Cuál es el volumen relativo de reclamaciones frente a opiniones en los informes actuales?
- ¿Existen diferencias significativas en las métricas de participación (vistas, likes, compartidos) entre ambos tipos de contenido?
- ¿Cómo afecta el estado de verificación al alcance del contenido?

Executive Report: TikTok Claims Classification (EDA Phase)

Project: TikTok Content Moderation | Client: TikTok Data Strategy Team PACE Phase: Analyze (Exploratory Data Analysis & Visualization)

Informe Ejecutivo: Preparación de Datos para Clasificación de Reclamaciones. Executive Report: Data Preparation for Claims Classification.

Data Exploration

Technical Analysis: Video Duration Box Plot
Análisis Técnico: Box Plot de Duración de Video

EN:Uniform Distribution: The box plot shows a remarkably uniform distribution. The median sits around 32 seconds, with the interquartile range (the blue box) spanning from approximately 18 to 48 seconds.

No Outliers: Unlike engagement metrics (views or likes), the video_duration_sec column contains no outliers. Every video in the dataset falls within the 5 to 60-second range, which is standard for short-form content.

Data Integrity: This indicates that the duration data is clean and does not require specialized capping or trimming before being used in a machine learning model.

ES:Distribución Uniforme: El box plot muestra una distribución notablemente uniforme. La mediana se sitúa alrededor de los 32 segundos, con el rango intercuartílico (la caja azul) abarcando aproximadamente desde los 18 hasta los 48 segundos.

Sin Valores Atípicos (Outliers): A diferencia de las métricas de interacción (vistas o likes), la columna video_duration_sec no contiene outliers. Cada video en el dataset cae dentro del rango de 5 a 60 segundos, lo cual es el estándar para contenido de formato corto.

Integridad de Datos: Esto indica que los datos de duración están limpios y no requieren de recortes o tratamientos especiales antes de ser utilizados en un modelo de machine learning.

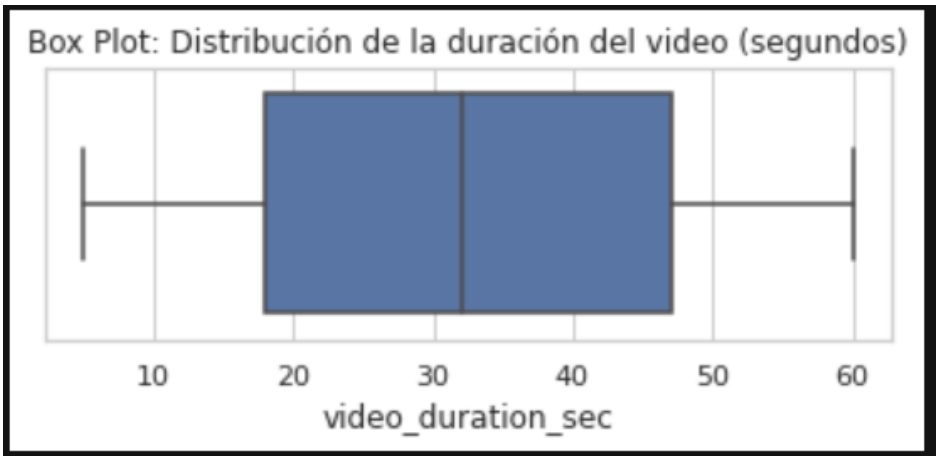

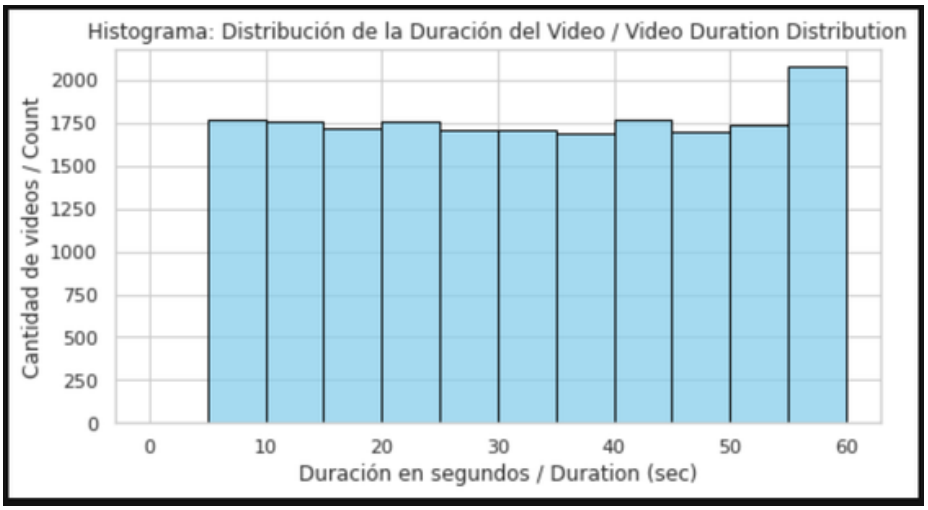

Executive Report: TikTok Claims Classification (EDA Phase)

Project: TikTok Content Moderation | Client: TikTok Data Strategy Team PACE Phase: Analyze (Exploratory Data Analysis & Visualization)

Visual Insights: View vs. Like Correlation
Hallazgos Visuales: Correlación entre Vistas y Likes

Data Exploration

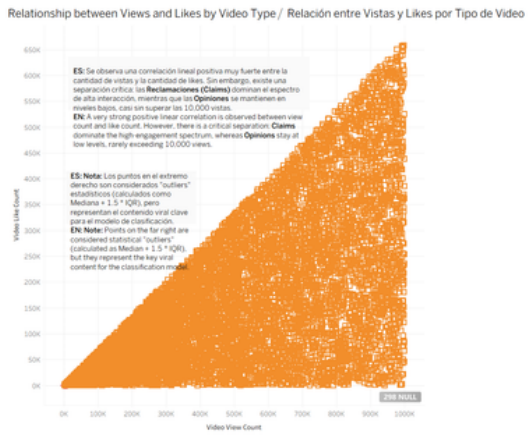

Right-Skewed Distribution: The data is heavily concentrated on the left. The first bin (0 to 100,000 likes) contains more than 12,000 videos, which is roughly 60% of the entire dataset.

Rapid Decay: There is a sharp drop-off in frequency as the number of likes increases. Very few videos reach the higher tiers (400k-700k likes).

Significance: This suggests that "liking" is a much more selective action than "viewing." While many videos get views, only a specific subset (likely the claims) generates the high engagement seen in the tail of the histogram.

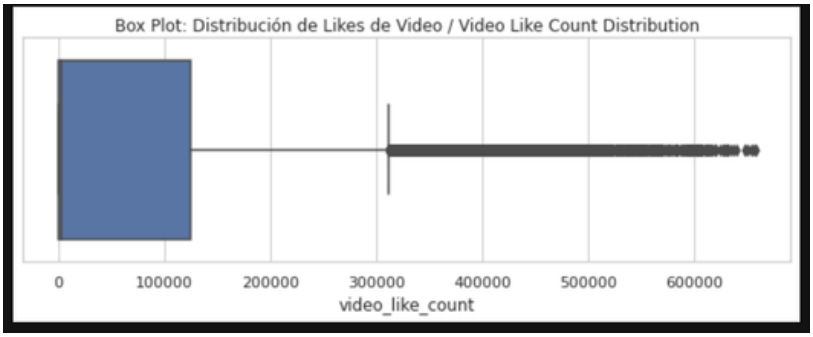

Distribución Sesgada a la Derecha: Los datos están fuertemente concentrados a la izquierda. El primer intervalo (0 a 100,000 likes) contiene más de 12,000 videos, lo que representa aproximadamente el 60% de todo el dataset.

Caída Rápida: Hay una disminución abrupta en la frecuencia a medida que aumenta el número de likes. Muy pocos videos alcanzan los niveles superiores (400k-700k likes).

Significado: Esto sugiere que dar "like" es una acción mucho más selectiva que "ver". Mientras que muchos videos obtienen vistas, solo un subconjunto específico (probablemente las reclamaciones) genera la alta interacción que se ve en la "cola" del histograma.

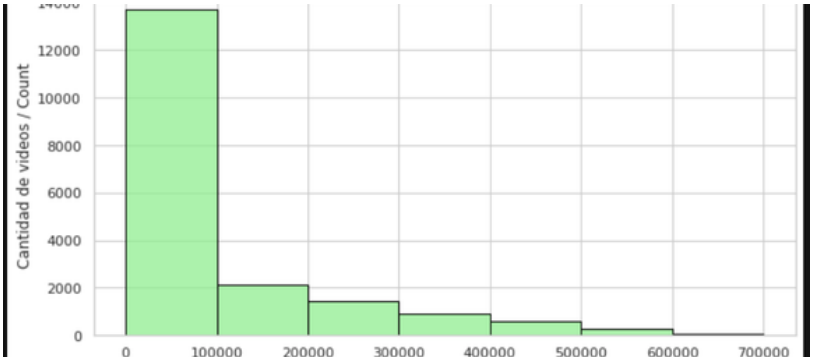

Executive Report: TikTok Claims Classification (EDA Phase)

Project: TikTok Content Moderation | Client: TikTok Data Strategy Team PACE Phase: Analyze (Exploratory Data Analysis & Visualization)

Visual Insights: View vs. Like Correlation
Hallazgos Visuales: Correlación entre Vistas y Likes

Data Exploration

Massive Right-Skew: The box plot shows that the vast majority of videos have nearly zero comments. The "box" itself is almost invisible because the median and the first/third quartiles are all concentrated at the very low end of the scale.

Extreme Outliers: There is a very dense "tail" of outliers extending toward 9,500 comments. This indicates that while the average video gets almost no conversation, a small number of videos trigger an explosion of comments.

Moderate vs. High Engagement: Most videos have a comment count that doesn't even reach 2,000, but the outliers create a long horizontal line that characterizes a "Power Law" distribution.

Sesgo a la Derecha Masivo: El box plot muestra que la gran mayoría de los videos tienen casi cero comentarios. La "caja" en sí es casi invisible porque la mediana y el primer/tercer cuartil están concentrados en el extremo más bajo de la escala.

Outliers Extremos: Hay una "cola" muy densa de valores atípicos que se extiende hacia los 9,500 comentarios. Esto indica que, mientras que el video promedio casi no genera conversación, un pequeño número de videos provoca una explosión de comentarios.
Interacción Moderada vs. Alta: La mayoría de los videos tienen un conteo de comentarios que ni siquiera llega a los 2,000, pero los outliers crean una línea horizontal larga que caracteriza una distribución de "Ley de Potencia".

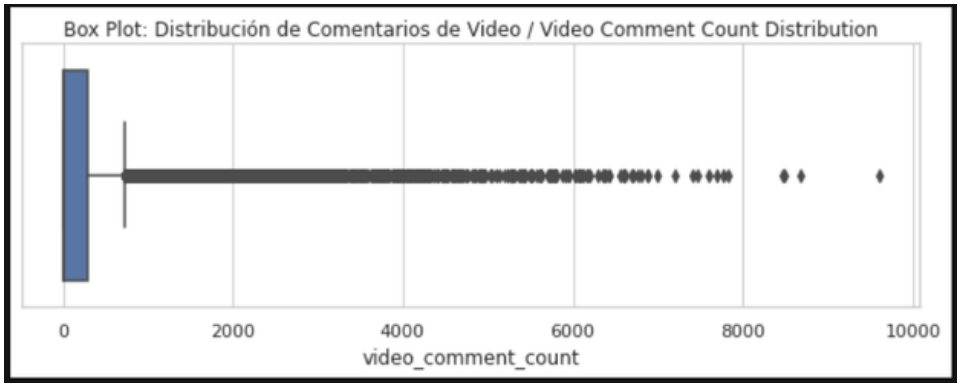

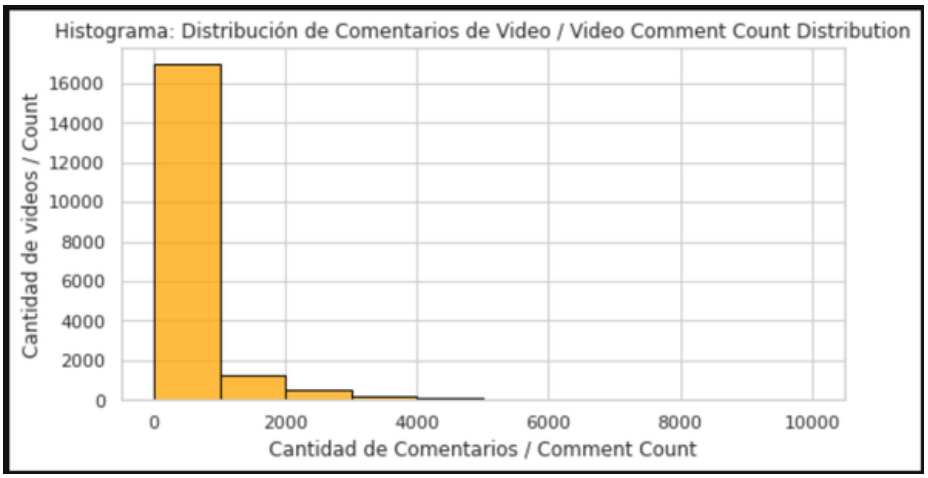

Executive Report: TikTok Claims Classification (EDA Phase)

Project: TikTok Content Moderation | Client: TikTok Data Strategy Team PACE Phase: Analyze (Exploratory Data Analysis & Visualization)

Estatus de verificación vs. Estatus de reclamación

Data Exploration

Unverified Users and Claims:

Approximately 97.8% of all claims are posted by unverified accounts. This suggests that verified_status is an extremely high-priority feature for our predictive model.

Notice how the "not verified" bar for claims is significantly taller than the "verified" bar in the same category.

Verified Users and Opinions: Conversely, verified users are much more likely to be associated with opinions than with claims.

Imbalance for Modeling: This suggests that verified_status is a strong predictor for claim_status. For the Orion model, an unverified account might be a "red flag" when trying to identify potential claims that need moderation.

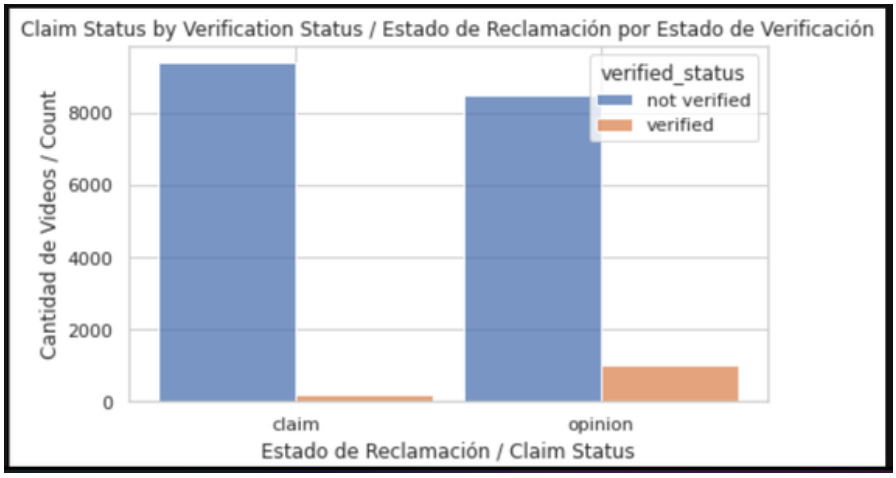

ES: “El 97.8% de las reclamaciones provienen de cuentas no verificadas. Esta disparidad confirma que el estado de verificación es la señal principal para identificar posibles violaciones de políticas.”

Observa cómo la barra de "no verificado" para claims es significativamente más alta que la barra de "verificado" en la misma categoría.

Usuarios Verificados y Opiniones: Por el contrario, es mucho más probable que los usuarios verificados estén asociados con opiniones que con reclamaciones.

Desequilibrio para el Modelado: Esto sugiere que verified_status es un predictor fuerte para claim_status. Para el modelo de Orion, una cuenta no verificada podría ser una "bandera roja" al intentar identificar reclamos potenciales que necesitan moderación.

Executive Report: TikTok Claims Classification (EDA Phase)

Project: TikTok Content Moderation | Client: TikTok Data Strategy Team PACE Phase: Analyze (Exploratory Data Analysis & Visualization)

Estatus de baneo vs. Estatus de reclamación

Data Exploration

The Safety of Opinions / La Seguridad de las Opiniones

EN: Look at the "opinion" bars. The overwhelming majority of authors are active (the blue bar). There are almost no "banned" or "under review" authors in this category. This confirms that sharing personal views is generally safe and doesn't violate community guidelines.

ES: Mira las barras de "opinion". La gran mayoría de los autores están activos (la barra azul). Casi no hay autores "baneados" o "bajo revisión" en esta categoría. Esto confirma que compartir puntos de vista personales es generalmente seguro y no viola las normas de la comunidad.

The Risk of Claims / El Riesgo de las Reclamaciones

- EN: "Claims are far more likely to be associated with penalized accounts. Over 31% of authors in the 'claim' category are either banned or under review, highlighting a strong correlation between content type and author history."
- ES: "Las reclamaciones tienen una probabilidad mucho mayor de estar asociadas a cuentas penalizadas. Más del 31% de los autores en la categoría 'claim' están baneados o bajo revisión, destacando una fuerte correlación entre el tipo de contenido e historial del autor."

verified_status	not verified	verified
claim_status		
claim	97.824729	2.175271
opinion	89.542001	10.457999

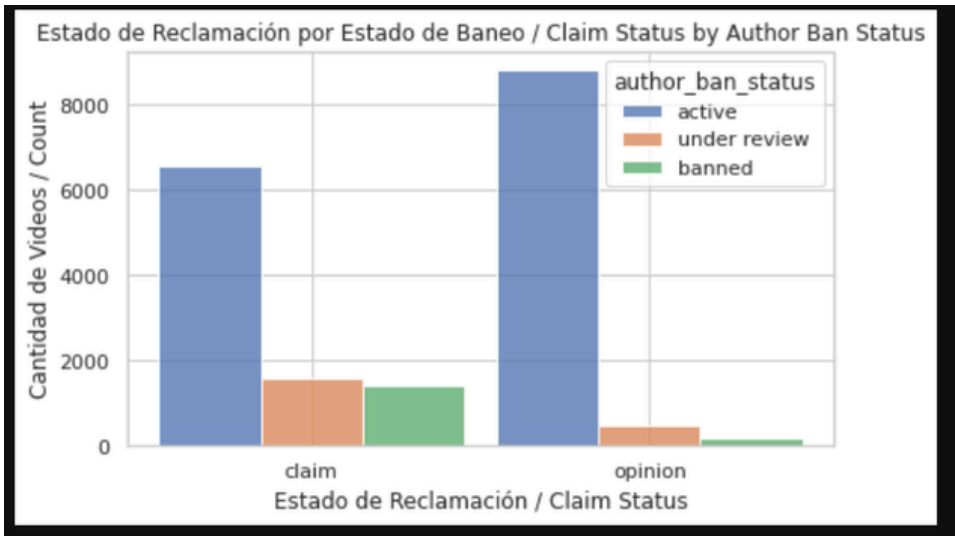

Executive Report: TikTok Claims Classification (EDA Phase)

Project: TikTok Content Moderation | Client: TikTok Data Strategy Team PACE Phase: Analyze (Exploratory Data Analysis & Visualization)

Estatus de baneo vs. Estatus de reclamación.

Data Exploration

The Safety of Opinions / La Seguridad de las Opiniones

EN: Look at the "opinion" bars. The overwhelming majority of authors are active (the blue bar). There are almost no "banned" or "under review" authors in this category. This confirms that sharing personal views is generally safe and doesn't violate community guidelines.

ES: Mira las barras de "opinion". La gran mayoría de los autores están activos (la barra azul). Casi no hay autores "baneados" o "bajo revisión" en esta categoría. Esto confirma que compartir puntos de vista personales es generalmente seguro y no viola las normas de la comunidad.

The Risk of Claims / El Riesgo de las Reclamaciones

EN: While many authors remain active, there is a clear high-risk signal: 31.6% of claim authors are already sanctioned (15% banned, 16.6% under review). This contrasts sharply with opinions, where only 7% face such status, proving that author history is a key predictor for content moderation.

ES: Aunque muchos autores siguen activos, existe una clara señal de riesgo: el 31.6% de los autores de reclamaciones ya están sancionados (15% baneados, 16.6% bajo revisión). Esto contrasta drásticamente con las opiniones, donde solo el 7% presenta este estado, demostrando que el historial del autor es un predictor clave para la moderación.

Why this matters / Por qué esto importa

EN: This visualization proves that there is a "signal" in the data: problematic content (claims) is already being caught by TikTok's systems, leading to bans. Our model will use this history to predict future violations.

ES: Esta visualización demuestra que hay una "señal" en los datos: el contenido problemático (reclamaciones) ya está siendo detectado por los sistemas de TikTok, lo que lleva a baneos. Nuestro modelo usará este historial para predecir violaciones futuras.

author_ban_status	active	banned	under review
claim_status			
claim	68.338884	14.977102	16.684013
opinion	93.045589	2.068383	4.886028

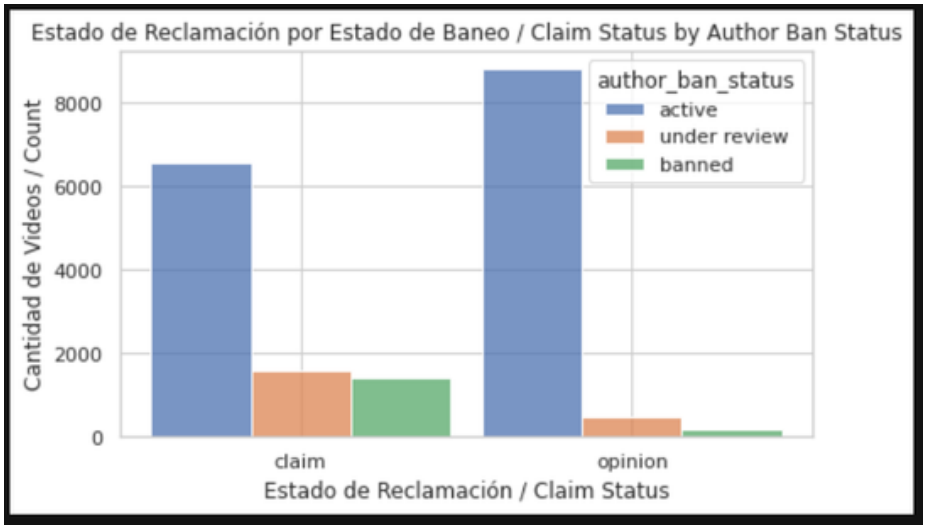

"There is a stark difference between the two. Authors of opinions are rarely banned, maintaining a mostly active status. In contrast, authors of claims show a significantly higher rate of being banned or under review, indicating that factual claims are the primary source of policy violations."

Hay una diferencia marcada entre ambos. Los autores de opiniones rara vez son baneados, manteniendo un estado mayoritariamente activo. Por el contrario, los autores de reclamaciones muestran una tasa significativamente mayor de estar baneados o bajo revisión, lo que indica que las afirmaciones fácticas son la fuente principal de violaciones de las políticas.

Executive Report: TikTok Claims Classification (EDA Phase)

Project: TikTok Content Moderation | Client: TikTok Data Strategy Team PACE Phase: Analyze (Exploratory Data Analysis & Visualization)

Next Steps & Conclusions / Conclusiones y Próximos Pasos,

EN: Final EDA Insights

- Predictive Power: The exploratory analysis confirms that verified_status and author_ban_status are the most critical indicators for content classification. The vast majority of claims are linked to unverified and previously penalized accounts.
- Modeling Readiness: With these clear signals identified, the dataset is highly suitable for machine learning. We will prioritize these features to build an efficient model that automates claim detection and optimizes moderation resources.

ES: Conclusiones Finales del EDA

- Poder Predictivo: El análisis exploratorio confirma que el estado de verificación (verified_status) y el estado de baneo del autor (author_ban_status) son los indicadores más críticos para la clasificación del contenido. La gran mayoría de las reclamaciones están vinculadas a cuentas no verificadas y previamente sancionadas.
- Preparación para el Modelado: Al haber identificado estas señales claras, el conjunto de datos es óptimo para el aprendizaje automático. Priorizaremos estas variables para construir un modelo eficiente que automatice la detección de reclamaciones y optimice los recursos de moderación.